Análise comparativa do desempenho de uma arquitetura de CPU Híbrida

Yuri Theodoro da Silva, Vinícius Garcia Pinto

Centro de Ciências Computacionais Universidade Federal do Rio Grande (FURG), Rio Grande – RS – Brasil

yuritheodorods@gmail.com, vinicius.pinto@furg.br

Resumo. Este artigo tem como objetivo analisar o desempenho de uma arquitetura de CPU híbrida, analisando o impacto da tecnologia SMT e do aumento dinâmico da frequência do processador. Para isso, avaliamos métricas como tempo médio de execução e aceleração, comparando uma arquitetura homogênea convencional com uma arquitetura híbrida. Na arquitetura homogênea o tempo de execução é relativamente estável, enquanto na híbrida há variações mais significativas, assim como observamos que o SMT teve um impacto maior na híbrida.

1. Introdução

O OpenMP é uma API que oferece suporte à programação paralela em memória compartilhada para as linguagens C, C++ e Fortran. Ele permite o desenvolvimento de aplicações paralelas em diversas plataformas como desktops e supercomputadores. A especificação do OpenMP é mantida pela OMP Architecture Review Board (ARB) [OpenMP ARB 2025] .

O NAS Parallel Benchmarks (NPB) é um grupo de programas desenvolvido pela Divisão de Supercomputação Avançada da NASA, com o intuito de avaliar o desempenho de supercomputadores paralelos. Esses benchmarks são amplamente reconhecidos como indicadores padrão de desempenho em computação e estão disponíveis em três versões, sendo elas NPB-MPI (versão paralelizada com MPI, bastante usada para execução em clusters e sistemas distribuídos.), NPB-OMP (versão paralelizada com OpenMP, mais recomendada para execução em sistemas de memória compartilhada (SMP) e NPB-Serial (Implementação sequencial usada como referência para comparação de desempenho) [NAS 2025].

No contexto do hardware, diversas tecnologias foram desenvolvidas a fim de aprimorar o desempenho de processadores modernos. O *Simultaneous Multithreading* (SMT) torna possível a execução de múltiplos threads em cada núcleo físico, permitindo que ele processe duas tarefas ao mesmo tempo, o que pode melhorar o desempenho ao distribuir melhor a carga de trabalho, tornando o processamento mais eficiente. O Hyper-Threading é uma implementação de SMT disponível em processadores Intel.O Turboboost, por sua vez, é outra tecnologia da Intel, que faz o ajuste dinamicamente na velocidade dos núcleos do processador além da frequência base quando há necessidade de mais desempenho. O que faz com que o processador possa trabalhar mais rápido em momentos de alta demanda para concluir tarefas intensivas de forma mais eficiente. Entretanto, o Sistema Operacional não controla em quais momentos tal ajuste ocorrerá, o único controle possível é desativar o mesmo por completo.

Mais recentemente, a Intel introduziu uma arquitetura híbrida com dois tipos diferentes de núcleos, os P-cores (*Performance-cores*) e E-cores (*Efficient-cores*). Os P-cores foram projetados para auxiliar em tarefas que exijam alto desempenho, como por exemplo jogos e edição de vídeo, enquanto os E-cores tem o foco em eficiência energética, o que o torna ideal para tarefas em segundo plano. Essa combinação permite um gerenciamento melhor e mais equilibrado da carga de trabalho, combinando desempenho e eficiência energética de forma inteligente [Intel 2025].

Neste trabalho, analisamos o impacto do Hyper-Threading (SMT) no desempenho dos clusters Tuco-Tuco e Vagoneta, tanto com 1 thread quanto multithread, avaliando o tempo médio de execução e a aceleração. A Seção 2 apresenta a metodologia usada para a realização dos testes. Na Seção 3 apresentamos e discutimos os resultados dos testes e seu impacto no desempenho dos clusters. Por fim, na Seção 4, concluímos o estudo e apontamos ideias para trabalhos futuros.

2. Trabalhos Relacionados

Diversos estudos exploram a otimização de desempenho em arquiteturas multicore assimétricas, como o Intel Alder Lake. O trabalho [Moori et al. 2024] mostra como a distribuição eficiente de threads entre P-cores e E-cores pode melhorar o desempenho de programas paralelos. O trabalho [Saez and Prieto-Matias 2022] investiga como a tecnologia Intel Thread Director otimiza a alocação de tarefas entre núcleos. Esses trabalhos são fundamentais para aprimorar o uso do OpenMP e a execução em sistemas modernos com múltiplos núcleos. Além disso, o trabalho [Gonçalves et al. 2024] demonstra como a variabilidade de processos na arquitetura Alder Lake pode afetar o desempenho e a eficiência energética, com a diferença de até 42% no energy-delay product (EDP) entre núcleos com as mesmas características. Isso destaca a importância de levar em conta variações de desempenho entre núcleos ao otimizar o equilíbrio entre desempenho e consumo energético, especialmente em arquiteturas heterogêneas.

3. Metodologia

A fim de avaliar o impacto das tecnologias de paralelismo no desempenho dos processadores, foram realizados testes utilizando a aplicação Embarrassingly Parallel (EP) do NPB. Essa aplicação foi escolhida pois realiza apenas cálculos paralelos sem dependência entre tarefas, o que permitiu uma análise mais direta do efeito do número de threads e das características dos núcleos do processador. Os testes foram divididos em dois principais experimentos, onde no primeiro variamos o número de threads para medir o speedup, ou seja, como o desempenho melhora à medida que mais threads são utilizadas. No segundo experimento, rodamos a aplicação de forma sequencial, alterando o code ID, que define em quais núcleos do processador a execução ocorre. Isso nos permitiu comparar o desempenho entre tipos diferentes de núcleos, como os P-cores e E-cores.

Os testes foram executados em duas máquinas distintas para avaliar o impacto do hardware. A primeira máquina possui um processador Intel Core i9 de 14 geração,

com núcleos híbridos (8 P-cores e 16 E-cores) e suporte a Hyper-Threading nos P-Cores executando Ubuntu Server 24.04 LTS. A segunda máquina conta com dois processadores Intel Xeon E5-2640 v3, com 8 núcleos homogêneos e SMT e roda o sistema operacional Linux CentOS 7.3. As execuções foram feitas utilizando o compilador GCC com suporte ao OpenMP. Para facilitar a identificação nos resultados, a máquina híbrida será referida como *Vagoneta*, enquanto a máquina com processadores homogêneos será chamada de *Tuco-Tuco*.

Para garantir resultados mais consistentes, foram realizadas cinco repetições de cada teste, registrando os tempos médios para análise. Esse número de repetições ajuda a diminuir variações ocasionais e permite obter uma avaliação mais precisa do comportamento do hardware sob diferentes tipos de execuções.

4. Resultados

Na Figura 1 podemos observar o tempo de execução das máquinas Tuco-Tuco e Vagoneta com 1 thread variando o núcleo CPU onde tal thread é executada, com e sem a presença de Hyper-Threading e Turbo Boost.

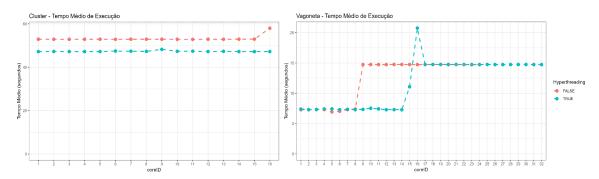


Figura 1. Tempo Médio 1 thread comparação

No Tuco-Tuco, o tempo de execução permanece estável e tem um leve aumento sem Hyper-Threading. Já na Vagoneta, há uma variação maior, com aumento significativo sem Hyper-Threading a partir do coreID 8 e um pico com Hyper-Threading no coreID 16. Isto pode ser explicado pois o Hyper-Threading está disponível apenas nos P-Cores (núcleos 0 a 7). Quando ele é desativado, os IDs 8 a 15 deixam de corresponder a núcleos lógicos dos P-Cores e passam a corresponder a E-Cores físicos. Nota-se que o impacto do Hyper-Threading foi muito maior na Vagoneta.

Já nas Figuras 2 e 3, temos os tempos médios e aceleração das duas máquinas, onde ambos se mantêm estáveis, com o tempo médio reduzindo conforme o número de threads aumenta e com o Tuco-Tuco tendo um desempenho um pouco melhor com o Hyper-Threading, porém com a Vagoneta sendo muito mais rápida, com um tempo de execução extremamente baixo comparado ao Tuco-Tuco.

5. Conclusão¹

O trabalho analisou o impacto do Hyper-Threading (SMT) no desempenho dos cluster Tuco-Tuco e Vagoneta, observando o tempo médio e aceleração tanto com 1 thread como multithread e comparou os resultados entre eles. Como resultado, podemos observar que na vagoneta ocorreram instabilidades com uma frequência maior, enquanto o Tuco-Tuco se mostrou mais estável.

Como trabalho futuro, propõe-se realizar outros testes com diferentes aplicações, avaliando o impacto do Hyper-Threading em situações diferentes, além de incluir métricas de consumo de energia.

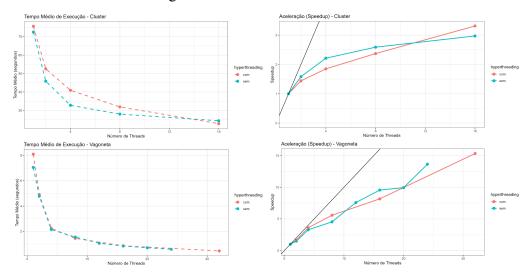


Figura 2. Tempo Médio Multithread

Figura 3. Aceleração Multithread

Referências

OpenMP Architecture Review Board. (2025) "The OpenMP API specification for parallel programming", https://www.openmp.org/, Acesso em Janeiro de 2025. NASA Advanced Supercomputing (NAS) Division. (2025) "NAS Parallel Benchmarks (NPB)" https://www.nas.nasa.gov/software/npb.htm, Acesso em Janeiro de 2025. Intel Corporation. (2025) "How Hybrid Design Works". Whitepaper, 2025. https://www.intel.com.br/content/www/br/pt/gaming/resources/how-hybrid-design-work s.html, Acesso em Janeiro de 2025.

Moori, M.K., Rocha, H.M.G.D.A., Lorenzon, A. F., & Beck, A. C. S (2024). Efficient Thread Tunning for Asymetric Multicores. *Proceedings of the 37th SBC/SBMicro/IEEE Symposium on Integrated Circuits and Systems Design (SBCCI)*, 1-5.

Saez, J. C., & Prieto-Matias, M.(2022). Evaluation of the Intel Thread Director Technology on an Alder Lake Processor. *Proceedings of the 13th ACM SIGOPS Asia-Pacific Workshop on Systems (APSys '22), 61-67.*

Gonçalves, T. dos S., Beck, A. C. S., & Lorenzon, A. F. (2024). Análise da Variabilidade de Processos na Execução de Tarefas em Arquiteturas Heterogêneas. *Anais da Escola Regional de Alto Desempenho da Região Sul (ERAD-RS)*, 24, 41-44.

¹ Trabalho parcialmente financiado pela FAPERGS (PROBIC e ARD/ARC 23/2551-0000861-0).